

MossAI: Ajuste espectral híbrido de espectros Mössbauer mediante aprendizaje automático

José David Bernal, Daniel José Duque, Salomón Urán¹

¹Facultad de Ciencias Exactas y Naturales, Universidad de Antioquia, Medellín, Colombia

Resumen

Este trabajo presenta **MossAI**, un pipeline para el análisis automatizado de espectros Mössbauer. El primer módulo aborda la clasificación química directa mediante redes neuronales de tipo MLP y CNN 1D entrenadas sobre 4094 espectros curados de la base de datos abierta NEMO/DEVAS (Mount Holyoke College). El segundo módulo propone un esquema híbrido de ajuste automático de parámetros hiperfinos que combina detección no supervisada de topología espectral (singletes, dobletes, sextetes) con refinamiento por mínimos cuadrados no lineales (`lmfit`), apoyado en la herramienta `PyMossFit`. Se reportan métricas reales obtenidas de la ejecución de ambos módulos, se discuten las limitaciones del acceso a bases de datos Mössbauer (mayoritariamente privativas o de pago) y se contextualiza el trabajo frente al historial experimental.

1. Introducción

La espectroscopía Mössbauer de ^{57}Fe permite determinar parámetros hiperfinos (corrimiento isomérico δ , desdoblamiento cuadrupolar ΔE_Q y campo hiperfino magnético B_{hf}) que identifican unívocamente la fase mineral o compuesto que contiene el núcleo sonda. El método tradicional de identificación exige que un espectroscopista experto reconozca visualmente la forma del espectro (número de singletes, dobletes o sextetes), proponga un modelo de ajuste y refine manualmente los parámetros, un proceso que puede tomar horas por espectro [1].

Recientemente, el aprendizaje automático se ha planteado como una alternativa para reducir la dependencia del criterio humano experto, tanto en Mössbauer como en espectroscopias afines. Por ejemplo en espectroscopia Raman e infrarroja se han desarrollado clasificadores que actúan directamente sobre las intensidades crudas del espectro; aquí, Carey et al. [2] mostraron que algoritmos de aprendizaje automático pueden reconocer y clasificar especies minerales a partir de los espectros Raman de una forma eficiente. También, Liu et al. [3] lograron extender este enfoque a redes convolucionales 1D que fueron capaces de clasificar cientos de especies minerales incluso en presencia de un fuerte desbalance de clases en la base de datos que usaron.

En el caso de espectroscopia Mössbauer, Henao et al. [1] demostraron que una red neuronal simple puede clasificar formas de espectros (caso de hematita vs magnetita vs otros) con mas del 95 % de exactitud, empleando únicamente intensidades del espectro como entrada, sin necesidad de hacer una manipulación previa de ellos. Aun así, el trabajo se limitó a tres formas espectrales con alto contraste y no hubo un desarrollo posterior de los ajustes

cuantitativos de los parámetros hiperfinos.

La propuesta de este trabajo retoma estas ideas metodológicas extendiéndolas en dos direcciones: (i) generalizar la clasificación a categorías químicas amplias sobre un dataset heterogéneo real, y (ii) automatizar la etapa de ajuste de parámetros hiperfinos mediante un esquema no supervisado, evitando la intervención manual del espectroscopista en la elección del modelo inicial.

En la sección 2 se aborda teóricamente el efecto Mössbauer discutiendo sus principios básicos. La sección 3 aborda la construcción de los algoritmos de aprendizaje automático, se presentan resultados de dichos algoritmos en la sección 4 y se concluye sobre estos en la sección 5.

2. Marco Teorico

La espectroscopia Mössbauer se basa en la emisión y absorción resonante de rayos gamma sin pérdida de energía por el retroceso nuclear, este fenómeno fue descubierto por Rudolf Mössbauer en 1958 al observar que, en un sólido, el momento de retroceso puede ser absorbido por la red cristalina completa en lugar del núcleo individual [4, 5]. Esto es lo que permite resolver, mediante efecto Doppler con un transductor mecánico, las variaciones de energía pequeñas del núcleo sonda (^{57}Fe) del orden de una parte en 10^{12} .

Estas variaciones de energía se caracterizan por tres parámetros hiperfinos, donde cada uno se asocia a una interacción distinta entre el núcleo y el entorno [5, 6]. El primero de ellos es el corrimiento isomérico δ que se produce por la interacción electrostática entre la densidad de electrones s en el núcleo y la carga nuclear, este varía con el estado de oxidación y el número de coordinación del

hierro, lo que permite distinguir por ejemplo entre Fe^{2+} y Fe^{3+} . Otro, es el desdoblamiento cuadruplicar ΔEQ , que surge de la interacción entre el momento cuadrupolar nuclear del estado excitado y el gradiente de campo eléctrico local. Este es sensible a la simetría del sitio cristalográfico que ocupe el átomo de hierro. Por ultimo, el campo hiperfino magnético B_{hf} , que aparece cuando existe un ordenamiento magnético específico en el material y produce desdoblamiento Zeeman nuclear en espectros de seis líneas.

Estas tres interacciones determinan la forma observable del espectro, lo que da un fundamento físico a la clasificación topológica que se usa en el modulo de ajuste (ver 3). Aquí, un singlete corresponde entonces a un sitio de hierro sin gradiente de campo eléctrico apreciable y sin ordenamiento magnético. Un doblete corresponde a un sitio con gradiente de campo eléctrico $\Delta EQ \neq 0$ pero sin ordenamiento magnético. Por ultimo el sextete corresponde a un sitio con ordenamiento $B_{hf} \neq 0$ independiente de si presenta además desdoblamiento cuadrupolar.

Estas correspondencias son las que permiten clasificar visualmente, con el numero de líneas y separación, los entornos de hierro que hay dentro de la muestra y por ende su clasificación.

3. Metodología

3.1. Fuente de datos y limitaciones de acceso

Los espectros utilizados provienen de la base de datos abierta *DEVAS Mössbauer Database* del Mount Holyoke College, curada por Dyar [7], accesible mediante el explorador NeMO. Es importante señalar que esta es una de las pocas bases de datos Mössbauer de acceso abierto disponibles públicamente, las bases de datos más extensas y sistemáticas de parámetros hiperfinos son de carácter privativo o requieren suscripción paga, lo que limita severamente la reproducibilidad y el entrenamiento de modelos de aprendizaje automático a gran escala en este campo. Esta restricción de acceso es, de hecho, una motivación adicional para automatizar al máximo el aprovechamiento de los datos abiertos disponibles.

3.2. Preprocesamiento y análisis exploratorio

Antes del modelado, se implementó un flujo de limpieza y preprocesamiento de los espectros para garantizar la consistencia física y geométrica de las señales. Las etapas aplicadas fueron:

1. **Filtrado de etiquetas:** se descartaron categorías minerales ambiguas o no informativas que no correspondían a fases puras bien definidas, así como registros duplicados en la base de datos.

2. **Criterio de consistencia física:** se removieron aquellos puntos singulares con velocidades fuera del rango operativo del transductor Doppler para la transición del ^{57}Fe . Asimismo, se excluyeron espectros completos cuyo rango de barrido excediera los límites físicos estándar de modulación.
3. **Homogeneización dimensional y normalización:** debido a la variabilidad en el número de canales de adquisición entre los diferentes espectrómetros, los vectores de intensidad se interpolaron mediante *splines* cúbicos utilizando la velocidad como variable independiente. Esto estandarizó los espectros a un número fijo de puntos uniformemente espaciados, seguido de una normalización de la intensidad.
4. **Agrupamiento químico:** las subcategorías minerales se reorganizaron en tres clases principales en función de su estructura y entorno de coordinación del hierro: *Óxidos/Hidróxidos*, *Silicatos* y *Otros* (que engloba sulfatos, fosfatos, haluros y fases metálicas).




Figura 1: Frecuencia de las subclases químicas originales antes de su agrupamiento en las 3 clases finales. Se aprecia el fuerte desbalance: piroxeno, óxido y olivino concentran la mayoría de las muestras.

Para ilustrar la naturaleza de los datos de entrada al clasificador, la Fig. 2 muestra varios espectros reales pertenecientes a una misma clase química (piroxeno, la subcategoría más numerosa del dataset). Se aprecia que, si bien todos comparten un patrón general de dos dobletes característico de esta familia mineral, existe una variabilidad considerable entre muestras individuales en la profundidad, el ancho y la resolución de las líneas de absorción, algunas incluso muestran un desdoblamiento adicional visible dentro de cada doblete, reflejo de diferencias reales en composición, tamaño de grano o condiciones de adquisición entre especímenes. Esta heterogeneidad intra-clase es precisamente lo que el clasificador debe aprender a generalizar, y contribuye a explicar por qué la exactitud de clasificación, aun siendo satisfactoria, dista de ser perfecta.

3.3. Clasificación directa de clase química

Siguiendo el principio metodológico de Henao *et al.* [1], se emplean directamente las intensidades del espectro como vector de entrada de una red neuronal, sin extracción




Figura 2: Ejemplos de espectros reales pertenecientes a la clase *Silicatos* (subcategoría piroxeno), tal como ingresan al clasificador tras el preprocesamiento. Cada color corresponde a una muestra distinta.

manual de características, se entrenaron dos arquitecturas sobre las mismas 3 clases químicas descritas arriba:

- **MLP Base:** `AdaptiveAvgPool1d(256) → Linear(256,128) → ReLU → Dropout(0.3) → Linear(128,64) → ReLU → Dropout(0.3) → Linear(64,3)`.
- **CNN 1D Base:** tres bloques convolucionales (`Conv1d+BatchNorm1d+ReLU+MaxPool1d`) con canales $1 \rightarrow 32 \rightarrow 64 \rightarrow 128$ y kernels de tamaño 7, 5 y 3, seguidos de `AdaptiveAvgPool1d(1)` y un clasificador denso ($128 \rightarrow 64 \rightarrow 3$).

Dado el desbalance de clases identificado, ambas redes se entrenaron con `FocalLoss` y pesos por clase calculados dinámicamente en cada *fold* de una validación cruzada estratificada de 5 particiones (`StratifiedKFold`), optimizando con Adam.

Es importante aclarar que estas dos arquitecturas se plantean, en primer instancia, como una prueba base (*baseline*) cuyo objetivo es determinar si la incorporación de capas convolucionales representa una ventaja real frente a una representación densa simple de la señal espectral. No se pretende agotar el espacio de arquitecturas posibles; en trabajos futuro pueden explorarse variantes más profundas, distintos tamaños y números de filtros, mecanismos de atención, u otras familias de modelos, una vez establecido si la convolución aporta valor sobre este problema particular.

3.4. Ajuste espectral híbrido no supervisado

La segunda gran componente del proyecto ataca el problema complementario: una vez identificada (o incluso sin identificar) la clase química, ¿se pueden extraer automáticamente los parámetros hiperfinos que un espectroscopista obtendría por ajuste manual? Un experto reconoce con relativa facilidad, a simple vista, patrones de singletes, dobletes y sextetes superpuestos, y usa ese reconocimiento

como punto de partida para el ajuste no lineal; sin embargo, ese reconocimiento visual y la elección del modelo inicial son precisamente el cuello de botella manual del método tradicional.

Para automatizar esta etapa se adoptó y extendió `PyMossFit` [8], una herramienta de código abierto basada en `lmfit` diseñada para ejecutarse de forma colaborativa en Jupyter/Google Colab, que incorpora doblado (*fold*) de datos crudos mediante transformada discreta de Fourier, suavizado con el algoritmo de Savitzky-Golay, y un paso de identificación de fases por k -vecinos más cercanos (KNN) contra una base local de parámetros hiperfinos de referencia. Se eligió `PyMossFit` por ser, una herramienta de ajuste Mössbauer de código abierto, en contraste con el software comercial predominante en el campo, que suele ser cerrado o con una curva de aprendizaje considerablemente mayor.

Sobre esa base se propone una combinación híbrida (no supervisada + optimización clásica) que evita el ajuste completamente manual: en lugar de que el usuario defina a priori el número de singletes (n_s), dobletes (n_d) y sextetes (n_x) (la “topología” del espectro), se implementaron y compararon seis estrategias de *model selection* no supervisado sobre el perfil de absorción del espectro:

- **peak heuristic** (regla basada en picos): cuenta los picos de absorción encontrados para estimar directamente la forma del espectro.
- **gmm** (Modelos de Mezclas Gaussianas): utiliza curvas en forma de campana para agrupar los datos según la intensidad, eligiendo la cantidad de componentes con el criterio BIC (Criterio de Información Bayesiano).
- **nmf** (Factorización de Matrices No Negativas): descompone la señal de absorción en partes más simples y define el número de componentes donde el error de reconstrucción deja de bajar rápido (método del codo).
- **dbscan peaks** (agrupamiento por densidad): agrupa los picos detectados según su cercanía para identificar si forman líneas solas (singletes), pares (dobletes) o conjuntos de seis (sextetos).
- **two phase** (ajuste en dos fases): prueba configuraciones básicas (un singlete, uno o dos dobletes, o un sextete), las ajusta repitiendo el cálculo desde diferentes puntos iniciales (*multi-start*) y elige la que da el menor error (RMSE o Error Cuadrático Medio).
- **bic grid** (búsqueda optimizada por BIC): realiza el mismo proceso de prueba de configuraciones que **two phase**, pero selecciona la mejor opción usando el criterio estadístico BIC en lugar del error RMSE.

Una vez propuesta la topología, los parámetros hiperfinos (δ , ΔE_Q , B_{hf} , ancho de línea) se refinan mediante minimización no lineal de `lmfit` con múltiples arranques

aleatorios (*multi-start*) para mitigar mínimos locales, y finalmente se contrastan contra una base de referencia de compuestos conocidos mediante KNN euclidiano sobre el espacio $(\delta, \Delta E_Q, B_{hf})$, heredado del diseño original de **PyMossFit**. Todo el proceso, desde la señal cruda hasta la lista de fases candidatas, ocurre sin intervención manual del usuario en la elección del modelo inicial.

Como propuesta metodológica, en este trabajo, los espectros analizados serán ajustados empleando las seis estrategias de *model selection* y se elegirá aquel resultado que minimice la función de pérdida.

3.5. Sobre el componente experimental y los datos históricos

Es importante contextualizar el origen y las limitaciones de los datos: si bien el foco de este trabajo es el dataset abierto NEMO/DEVAS, se intentó también incorporar y clasificar parte del registro histórico experimental del Grupo de Estado Sólido de la Universidad de Antioquia, acumulado a lo largo de varios años de trabajo del grupo. Sin embargo, esta componente experimental terminó representando una fracción pequeña del entrenamiento final, por varias razones concretas: (i) heterogeneidad de formatos de archivo entre equipos y épocas de adquisición; (ii) ausencia de una clasificación química sistemática asociada a muchos de los espectros históricos; (iii) presencia de datos corruptos o incompletos en archivos antiguos; (iv) espectros almacenados en crudo, es decir, en canales del multicanal sin la calibración a velocidad Doppler (mm/s) necesaria para ser comparables entre equipos y épocas; y (v) la imposibilidad práctica, durante el desarrollo de este trabajo, de adquirir nuevos espectros de calibración por falta de disponibilidad de una fuente radiactiva en el laboratorio. No obstante, se considera que la componente experimental propia es valiosa y debe seguir incorporándose: el presente trabajo debe entenderse como una prueba de concepto de lo que es posible automatizar, y no como el aprovechamiento final y exhaustivo del archivo histórico del grupo, cuya curación queda como trabajo futuro.

4. Resultados

4.1. Clasificación directa

La Tabla 1 resume las métricas obtenidas en la validación cruzada estratificada de 5 particiones para ambas arquitecturas.

Cuadro 1: Métricas de clasificación (media $\pm$ desviación estándar sobre 5 folds) para las 3 clases químicas.

Modelo	Exactitud	Macro-F1	F1 ponderado
CNN 1D Base	0,518 $\pm$ 0,134	0,461 $\pm$ 0,136	0,465 $\pm$ 0,156
MLP Base	0,759 $\pm$ 0,015	0,745 $\pm$ 0,021	0,750 $\pm$ 0,020

El resultado más notable es que el **MLP superó de forma consistente a la CNN 1D**, tanto en exactitud promedio (75.9 % vs. 51.8 %) como en estabilidad entre *folds* (desviación estándar de 0.015 vs. 0.134). Esto contrasta con la intuición de que una red convolucional debería ser más adecuada para detectar patrones locales (picos Lorentzianos) invariantes a traslación. Una posible explicación es que, con una cantidad limitada de espectros y una capa de **AdaptiveAvgPool1d** temprana en el pipeline, la CNN dispone de muy pocos datos para aprender los filtros convolucionales desde cero, mientras que el MLP, al operar sobre una representación reducida (Los canales de velocidad-intensidad) de la envolvente completa del espectro, captura más directamente diferencias globales de forma entre familias minerales (p.ej. el número y separación de los mínimos de absorción). Además, un *fold* particular de la CNN (fold 5) colapsó a una exactitud de apenas 0.254, señal de inestabilidad en el entrenamiento probablemente asociada al bajo número de épocas usado en la corrida reportada.

Es relevante comparar estas cifras con el 97 % de exactitud reportado por Henao *et al.* [1]: dicho trabajo clasificaba únicamente 3 clases muy contrastantes (hematita, magnetita, u “otro”), con formas de espectro extremadamente distintivas (1 sextete vs. 2 sextetes vs. formas variadas), mientras que el problema abordado aquí agrupa docenas de minerales estructuralmente diversos bajo 3 categorías más amplias (Óxidos/Hidróxidos, Silicatos, Otros), lo que constituye un problema de clasificación intrínsecamente más difícil y con fronteras de decisión menos nítidas.

Para complementar las métricas agregadas de la Tabla 1 con un análisis por clase, las Figs. 3 y 4 muestran las matrices de confusión normalizadas de ambos modelos sobre el conjunto de prueba.




Figura 3: Matriz de confusión normalizada por fila para la CNN 1D.




Figura 4: Matriz de confusión normalizada por fila para el MLP.

La matriz de confusión confirma y detalla la brecha de desempeño observada en la Tabla 1: mientras que ambos modelos reconocen razonablemente bien las clases *Óxidos/Hidróxidos* y *Silicatos*, la CNN tiene serias dificultades con la clase *Otros*, clasificándola correctamente solo el 53 % de las veces y confundiéndola con *Silicatos* en un 35 % de los casos. El MLP, en cambio, mantiene un desempeño mucho más equilibrado entre clases, incluyendo la clase *Otros* (86 % de aciertos), lo que sugiere que la CNN no logró generalizar bien la enorme variabilidad de formas espectrales que agrupa esta categoría, mientras que la representación global usada por el MLP resulta más robusta frente a esa heterogeneidad.

Adicionalmente, se evaluó la calibración de las probabilidades predichas mediante diagramas de confiabilidad multiclase (Figs. ?? y ??), que comparan la confianza media predicha por el modelo con la exactitud empírica observada en cada rango de confianza.

4.2. Ajuste espectral no supervisado

Las Figs. 5 y 6 ilustran el comportamiento del módulo de ajuste híbrido sobre dos espectros representativos del dataset, cada uno con una topología distinta detectada y refinada de forma completamente automática.




Figura 5: Ajuste automático no supervisado (PyMossFit) sobre un espectro representativo (Espectro A), correspondiente a una topología de dos dobletes bien resueltos.




Figura 6: Ajuste automático no supervisado (PyMossFit) sobre un segundo espectro representativo (Espectro B), de mayor nivel de ruido y con una topología de doblete ancho parcialmente resuelto.

Estos dos ejemplos permiten ilustrar de forma general el funcionamiento de la extensión propuesta sobre PyMossFit: en el Espectro A, de buena relación señal-ruido, el pipeline detecta con claridad dos componentes tipo doblete y el ajuste reproduce fielmente la profundidad y posición de ambas líneas de absorción. En el Espectro B, con mayor ruido experimental y líneas más anchas y solapadas, el pipeline logra igualmente converger a un ajuste razonable, aunque con mayor incertidumbre en los parámetros hiperfinos recuperados, evidenciando cómo la calidad de la señal original condiciona la confiabilidad del ajuste automático. En ambos casos, más allá de la topología simple mostrada aquí, el pipeline evalúa internamente si permitir combinaciones de componentes (por ejemplo, sumar un singlete a los dobletes) mejora el ajuste, y conserva mediante el criterio BIC la opción que ofrece el mejor compromiso entre bondad de ajuste y parsimonia del modelo, descartando automáticamente la complejidad adicional cuando esta no se traduce en una mejora real.

De esta manera, la extensión híbrida sobre PyMossFit no solo automatiza la elección inicial de la topología (Sección 3.4), sino también la decisión de cuánta complejidad estructural conviene admitir en el modelo final, evitando que el usuario deba comparar manualmente distintas configuraciones espectro por espectro.

El ajuste se ejecutó sobre un grupo pequeño de muestras debido al tiempo que toma procesar cada espectro. Los resultados demuestran que el método funciona bien

técnicamente, pero no se pueden validar de forma directa. Esto ocurre porque los datos originales no incluyen una etiqueta o clasificación clara del material que se está estudiando. Por lo tanto, el análisis masivo de todos los datos y la confirmación exacta de cada componente quedan como trabajo futuro.

5. Conclusiones

1. Se construyó un pipeline reproducible de dos etapas para espectroscopía Mössbauer que va desde datos crudos heterogéneos de la base abierta NEMO/DEVAS [7] hasta clasificación química y ajuste hiperfino automatizado, extendiendo la propuesta metodológica de Henao *et al.* [1] de una clasificación de 3 fases muy distintivas a un problema químico más amplio y realista de 3 categorías agregadas sobre 4094 espectros.
2. El modelo MLP superó de forma clara y estable a la CNN 1D (75.9% vs. 51.8% de exactitud), un resultado no trivial que sugiere que, en el régimen de datos disponible, representaciones globales simples de la forma espectral son más robustas que filtros convolucionales aprendidos desde cero; esto abre la puerta a explorar en trabajo futuro arquitecturas híbridas o preentrenamiento con datos sintéticos, como en Henao *et al.* [1]
3. Se demostró la viabilidad de reemplazar la elección manual del modelo de ajuste (número de singletes, dobletes y sextetes) por un esquema híbrido no supervisado sobre PyMossFit [8], que combina múltiples heurísticos de detección de topología con refinamiento por mínimos cuadrados no lineales y validación por KNN contra una base de compuestos de referencia, sin intervención del usuario.
4. El acceso restringido a bases de datos Mössbauer extensas (la mayoría de carácter privativo o de pago) continúa siendo la principal limitación estructural para escalar este tipo de modelos; el dataset NEMO/DEVAS, aunque valioso, es comparativamente pequeño para entrenar arquitecturas profundas de gran capacidad.
5. El aprovechamiento del archivo histórico experimental del Grupo de Estado Sólido de la Universidad de Antioquia resultó limitado en esta primera implementación por problemas de formato, ausencia de etiquetado, datos corruptos, espectros sin calibración a velocidad Doppler, y la imposibilidad de adquirir nuevas mediciones de calibración por falta de fuente radiactiva disponible durante el desarrollo del proyecto. Se enfatiza que la componente experimental propia sigue siendo estratégicamente importante y que este trabajo constituye una prueba de concepto

de las capacidades de automatización posibles, no un aprovechamiento exhaustivo de dicho archivo.

6. Como trabajo futuro se plantea: (i) ejecutar el módulo de ajuste híbrido sobre la totalidad del dataset y no solo sobre muestras representativas; (ii) usar las pseudo-etiquetas topológicas generadas por PyMossFit para entrenar un clasificador supervisado de topología, cerrando el ciclo semi-supervisado entre los módulos 2 y 3; y (iii) sistematizar y digitalizar el archivo histórico experimental del grupo para incorporarlo de forma más completa al entrenamiento.

Referencias

- [1] D. Henao, J. Lopez, J. Tobon, and C. Barrero, “Implementation of an artificial neural network in the identification of the Mössbauer spectral shape of hematite and magnetite,” *Hyperfine Interactions*, vol. 244, no. 11, 2023. <https://doi.org/10.1007/s10751-023-01821-w>
- [2] C. Carey, T. Boucher, S. Mahadevan, P. Bartholomew, and M. D. Dyar, “Machine learning tools for mineral recognition and classification from Raman spectroscopy,” *Journal of Raman Spectroscopy*, vol. 46, no. 10, pp. 894–903, 2015. <https://doi.org/10.1002/jrs.4757>
- [3] J. Liu, M. Osadchy, L. Ashton, M. Foster, C. J. Solomon, and S. J. Gibson, “One-Dimensional Deep Convolutional Neural Network for Mineral Classification from Raman Spectroscopy,” *Neural Processing Letters*, 2021. <https://doi.org/10.1007/s11063-021-10652-1>
- [4] R. L. Mössbauer, “Kernresonanzfluoreszenz von Gammastrahlung in Ir^{191} ,” *Zeitschrift für Physik*, vol. 151, pp. 124–143, 1958.
- [5] N. N. Greenwood and T. C. Gibb, *Mössbauer Spectroscopy*. London: Chapman and Hall, 1971.
- [6] P. Gülich, E. Bill, and A. X. Trautwein, *Mössbauer Spectroscopy and Transition Metal Chemistry: Fundamentals and Applications*. Berlin/Heidelberg: Springer, 2011. <https://doi.org/10.1007/978-3-540-88428-6>
- [7] M. D. Dyar, “Mössbauer dataset,” *DEVAS Database*, Mount Holyoke College, 2022. http://nemo.mtholyoke.edu/explorer?ds_kind=Mossbauer&ds_name=MHC%20Mossbauer
- [8] F. D. Saccone, “PyMossFit: A Google Colab Option for Mössbauer Spectra Fitting,” *Spectroscopy Journal*, vol. 3, no. 4, p. 29, 2025. <https://doi.org/10.3390/spectroscj3040029>

- [9] D. Bernal (JD314), “MossAI,” Repositorio de código, GitHub, 2026. <https://github.com/JD314/MossAI>